

画像のスパース表現の理論と 最適化アルゴリズム

富岡 亮太 (東京大学)

tomioka@mist.i.u-tokyo.ac.jp

スペース表現：2つの視点

- データの圧縮
 - 90年代: ウェーブレットにもとづくノイズ除去 [Donoho et al.]
 - 2000年代: 圧縮センシング [Candes et al.]
- モデルの圧縮
 - 90年代: L1正則化付き学習 [Tibshirani et al.]
 - 2000年代: マルチカーネル学習 [Lanckriet, Bach et al.]

データの圧縮の視点から

圧縮センシング

$$\underset{\boldsymbol{x}}{\text{minimize}} \quad \frac{1}{2} \|\boldsymbol{y} - \boldsymbol{A}\boldsymbol{x}\|_2 + \lambda \|\boldsymbol{\Psi}\boldsymbol{x}\|_{\star}$$

y: 観測

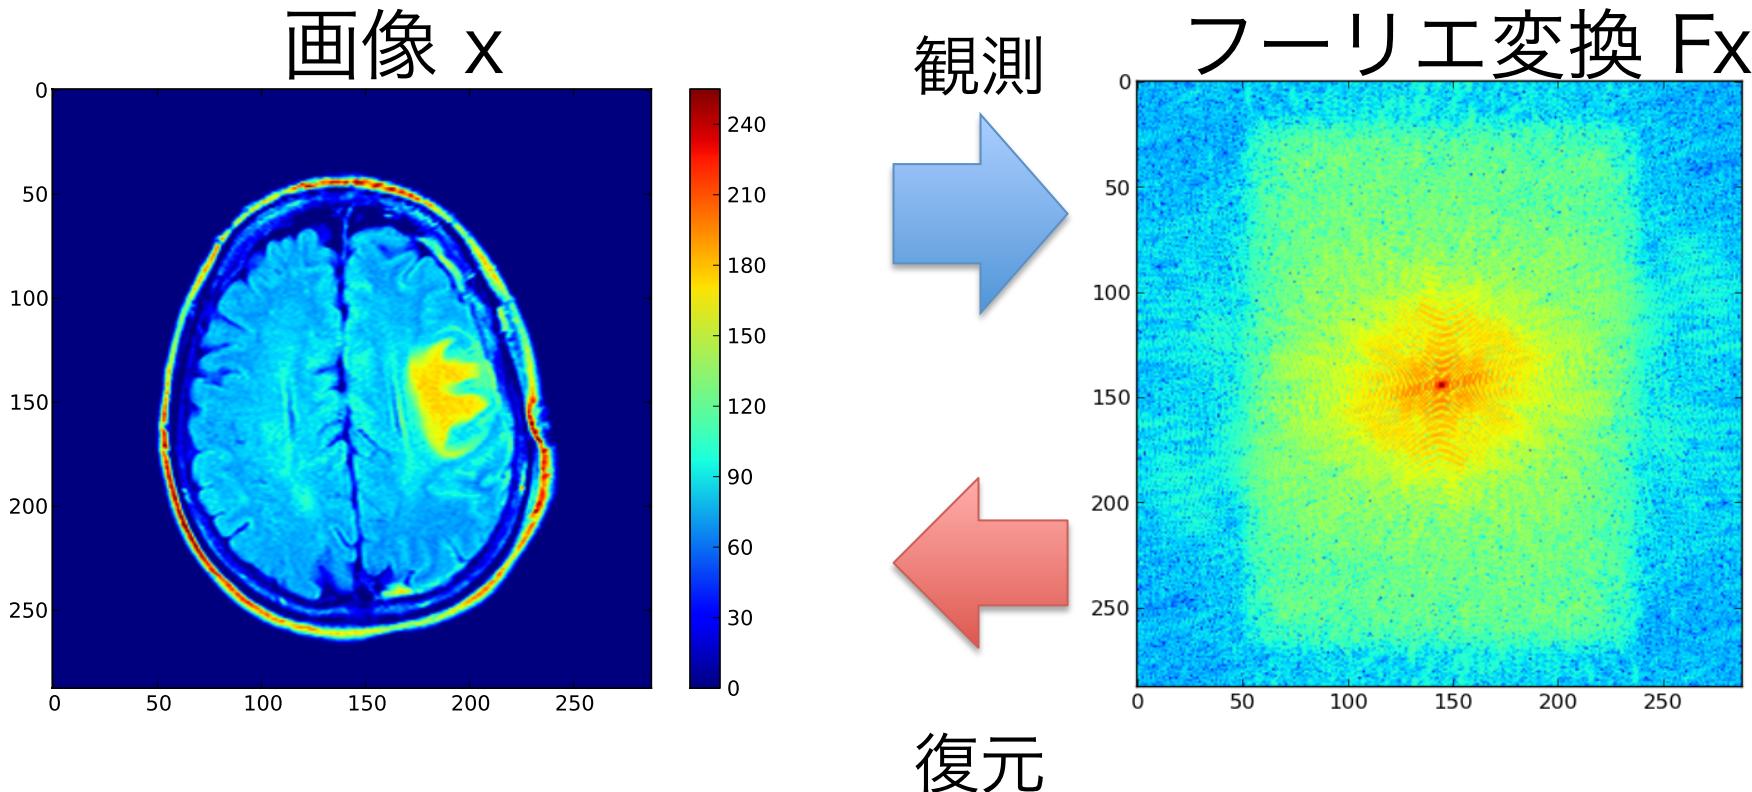
x: 復元したい量

A: デザイン行列 (観測の過程)

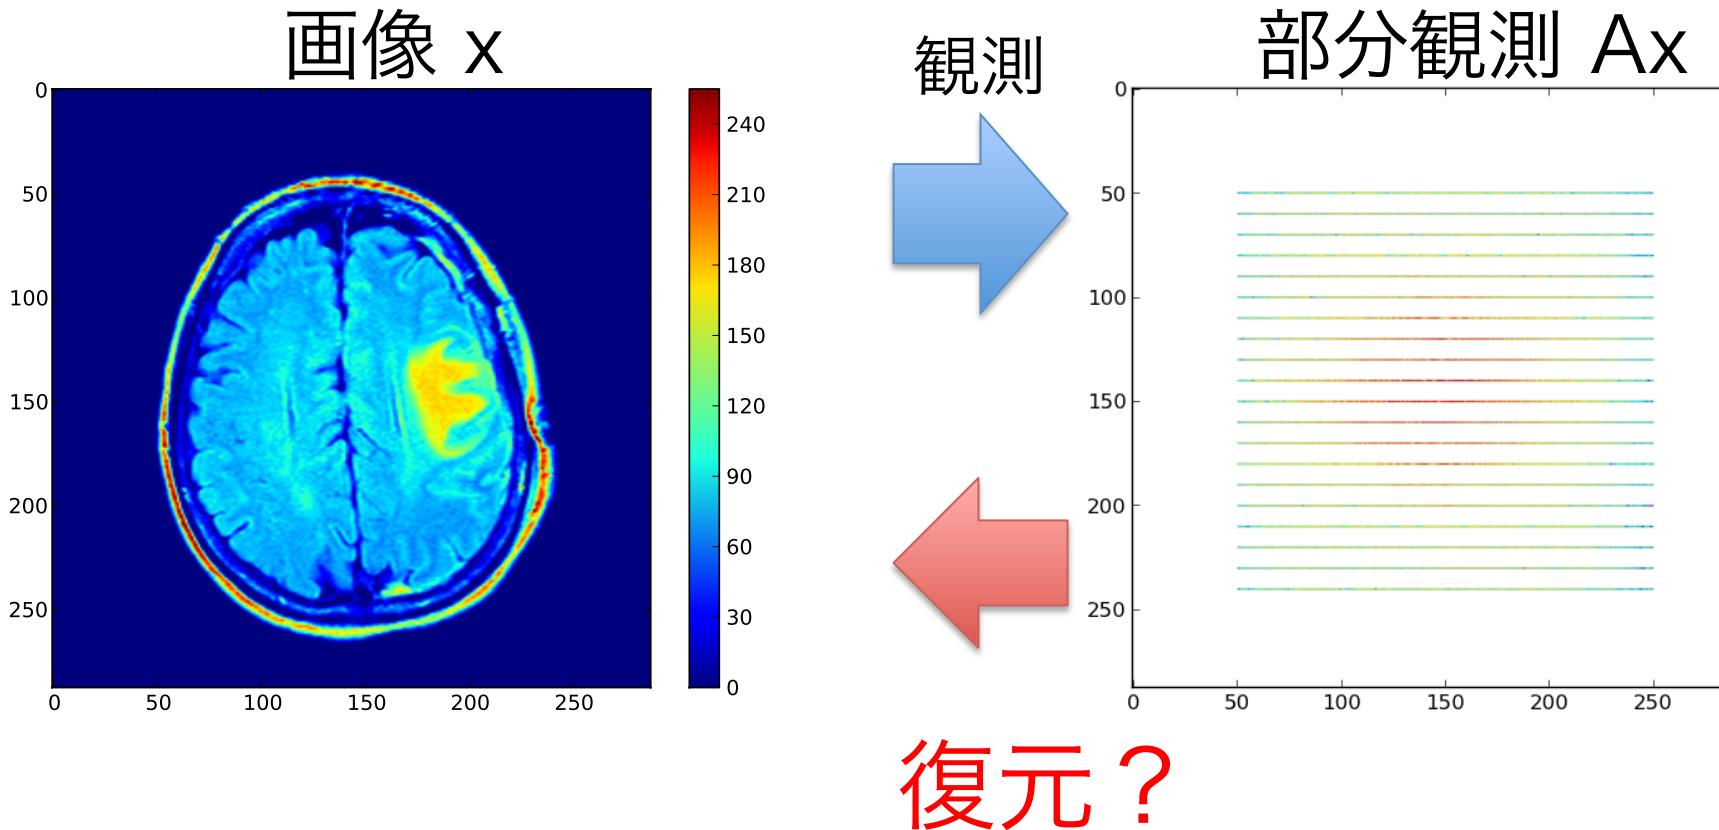
$\boldsymbol{\Psi}$: スパース基底 (例: ウェーブレット変換)

$\|\cdot\|_{\star}$: スパース性ノルム (例: L_1 ノルム)

圧縮センシング：部分観測からの復元



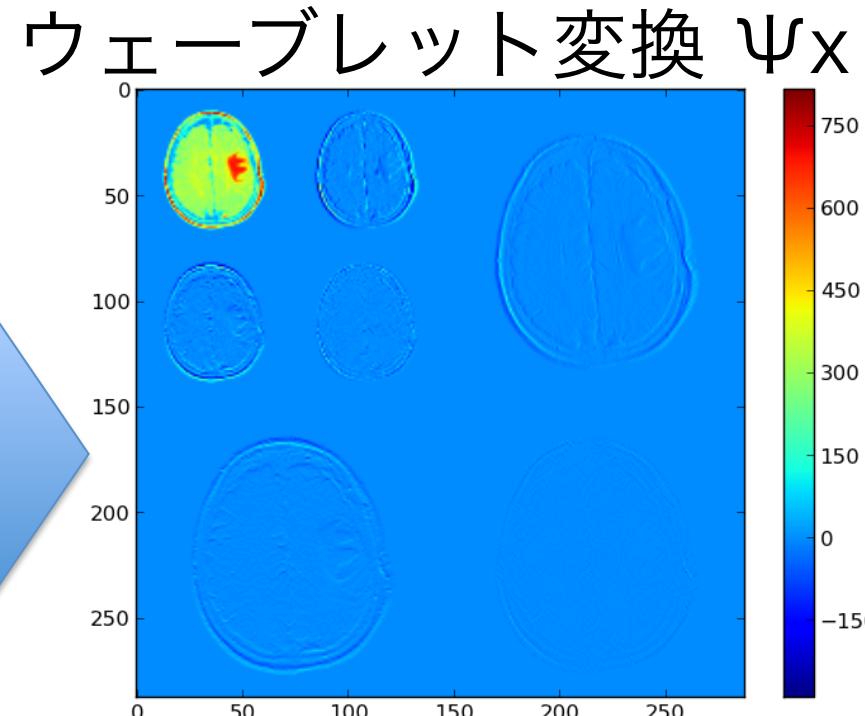
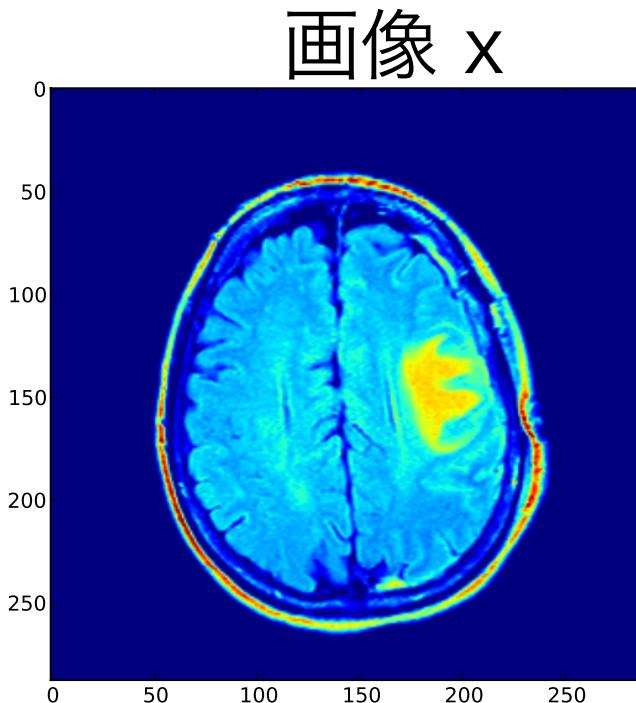
圧縮センシング：部分観測からの復元



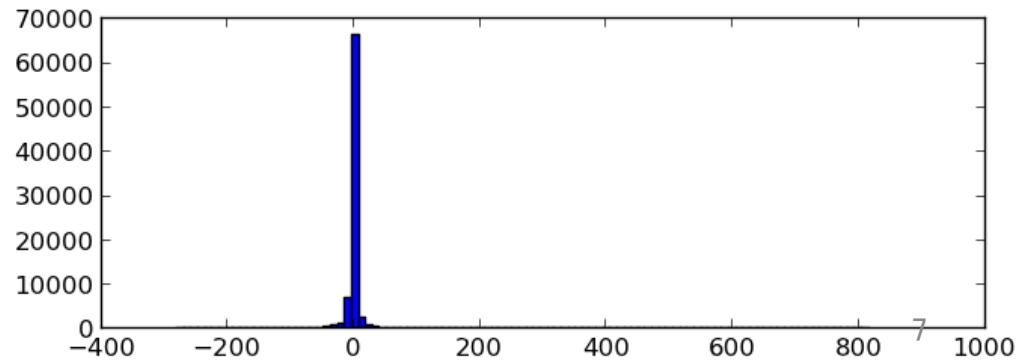
デザイン行列 A

→ フーリエ変換係数の一部を取り出す操作

MRI画像のスパース性



スパース基底 Ψ
→ ウェーブレット変換.
スパース性ノルム
→ L_1 ノルム.

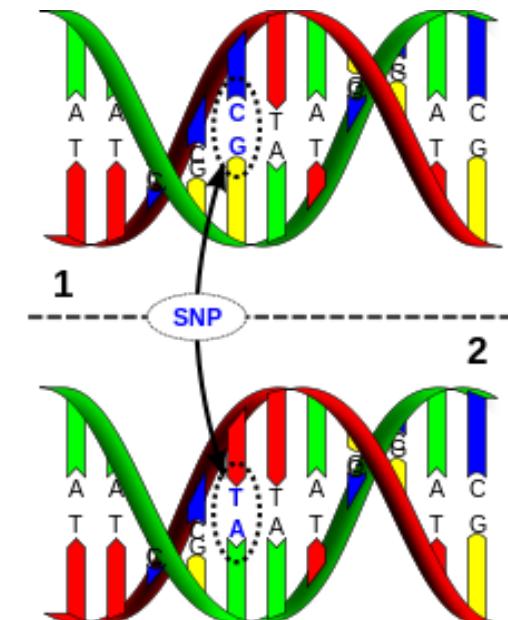


モデルの圧縮の視点から

L₁正則化付き学習—SNP（一塩基多型）解析

- SNPの数 $p=500,000$
- サンプル数 $n=5,000$

$p \gg n!!$



http://en.wikipedia.org/wiki/Single-nucleotide_polyorphism

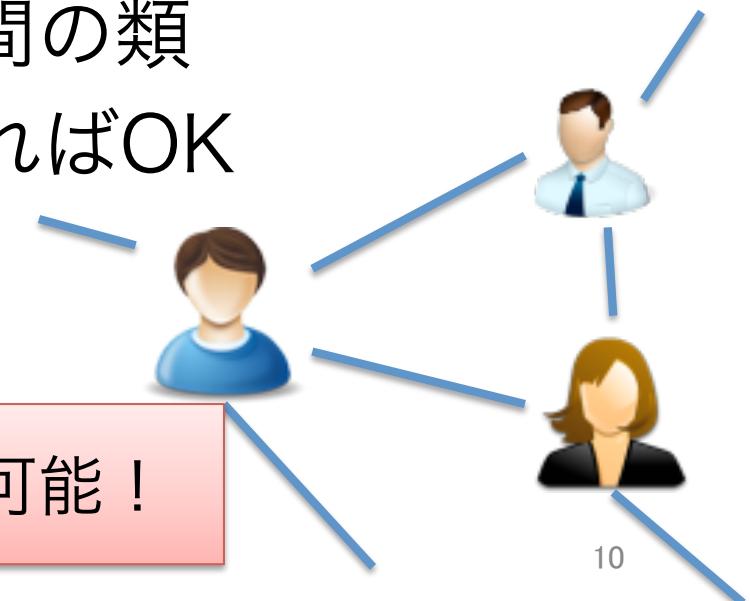
最適化問題: L₁正則化付きロジスティック回帰

$$\underset{w}{\text{minimize}} \quad L(y \circ Xw) + \lambda \|w\|_1$$

ロジスティック損失

カーネル法

- 特徴量の陽な表現一次元の呪い
 - オーバーフィット
 - 計算困難
- カーネル法
 - 特徴量の代わりにサンプル間の類似度（内積）さえ定義できればOK
 - 次元に依存しない理論



多くの学習アルゴリズムはカーネル化可能！

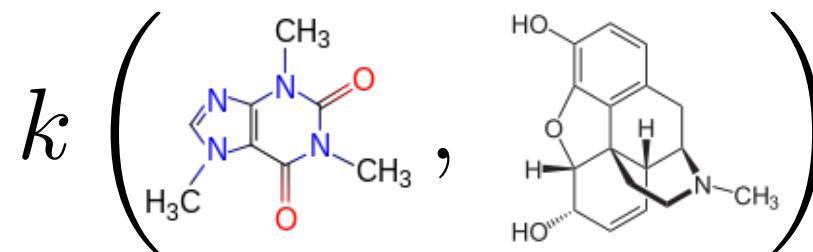
類似度（内積）の表現としてのカーネル

- カーネル関数は任意のオブジェクトの間の内積を表現可能

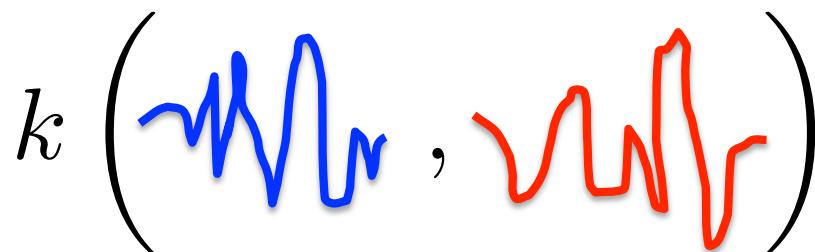
画像間の類似度



化学物質間の類似度



時系列間の類似度



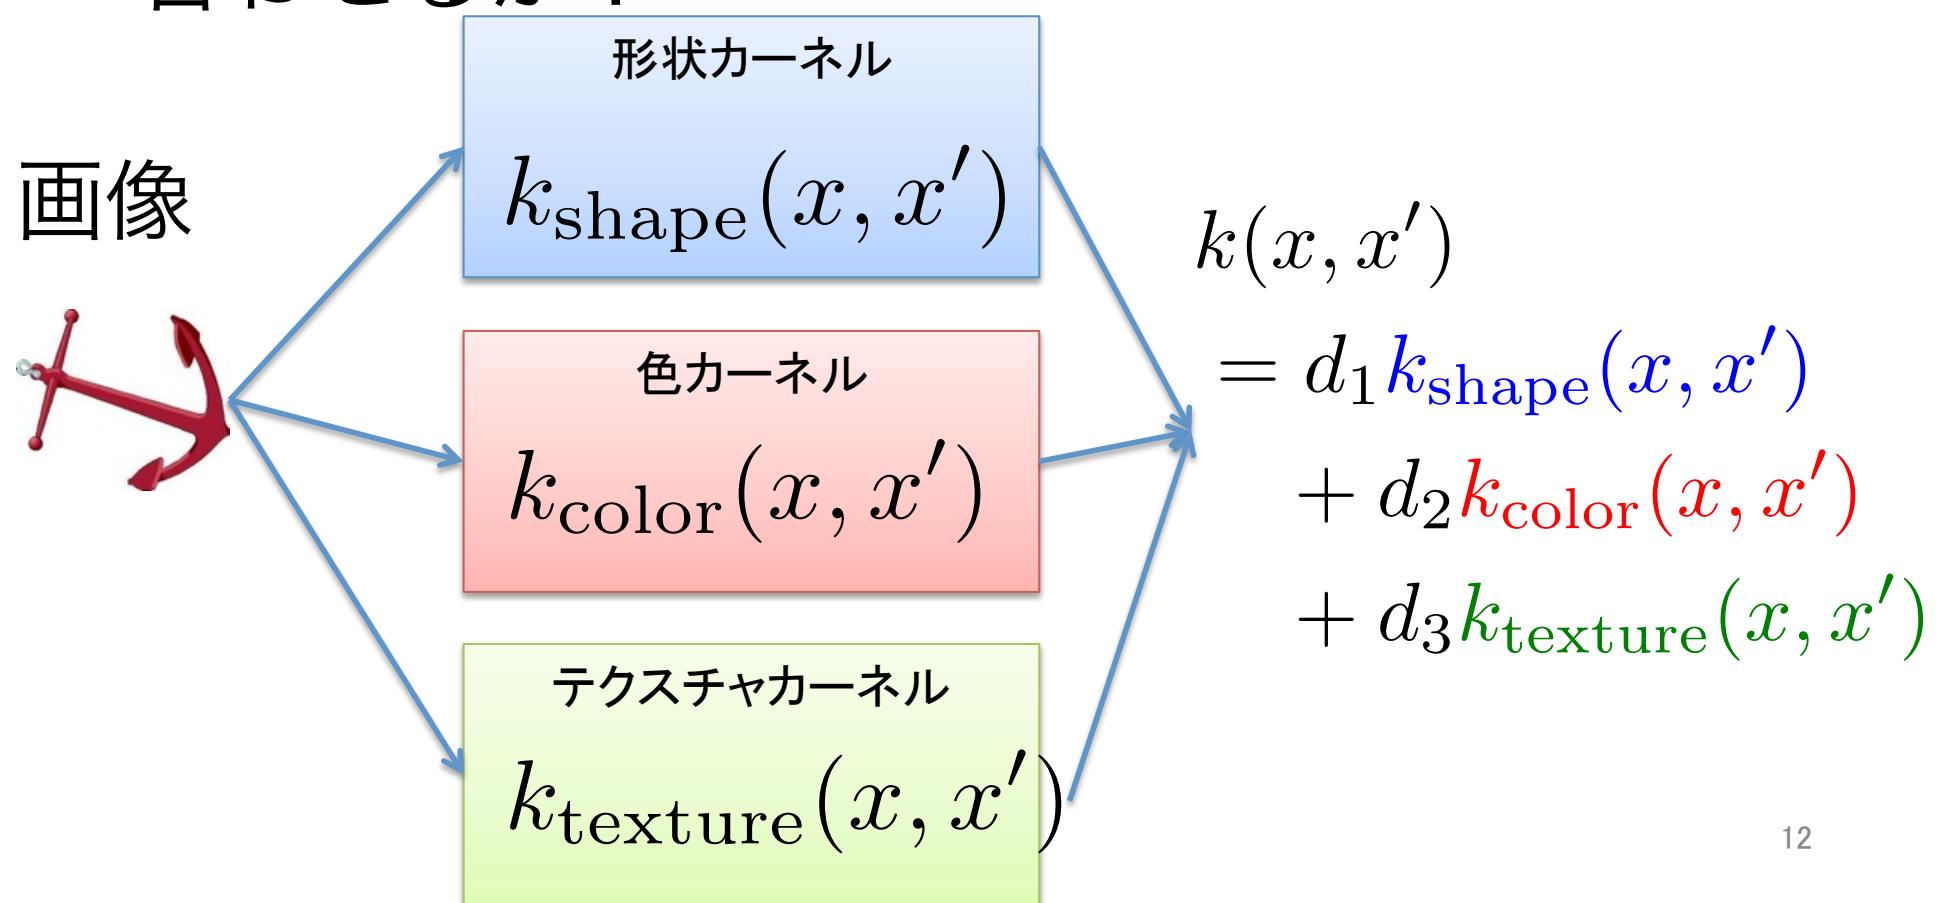
ユーザ間の類似度



マルチカーネル学習

[Lanckriet et al. 04;
Bach et al. 04;
Micchelli & Pontil 05]

- 多数の候補となるカーネルをいかに組み合わせせるか？



画像認識におけるカーネル選択

- 組み合わせ爆発！
 - Descriptor (SIFT, HueSIFT, etc.)
 - 空間分割、 spatial pyramid
 - ヒストグラムに対するカーネル関数
 - カーネル関数のパラメータ
- 1,000 – 10,000 候補カーネル

多数のカーネルにスケールするアルゴリズムが必要

最適化アルゴリズム

解きたい問題

- Type I
 - 圧縮センシングで Ψ^{-1} が存在する場合
 - L_1 正則化学習、マルチカーネル学習

$$\min_{\boldsymbol{x}} \quad L(\boldsymbol{x}) + \lambda \|\boldsymbol{x}\|_1$$

- Type II
 - 圧縮センシングで Ψ^{-1} が存在しない場合

$$\min_{\boldsymbol{x}} \quad L(\boldsymbol{x}) + \lambda \|\boldsymbol{\Psi}\boldsymbol{x}\|_1$$

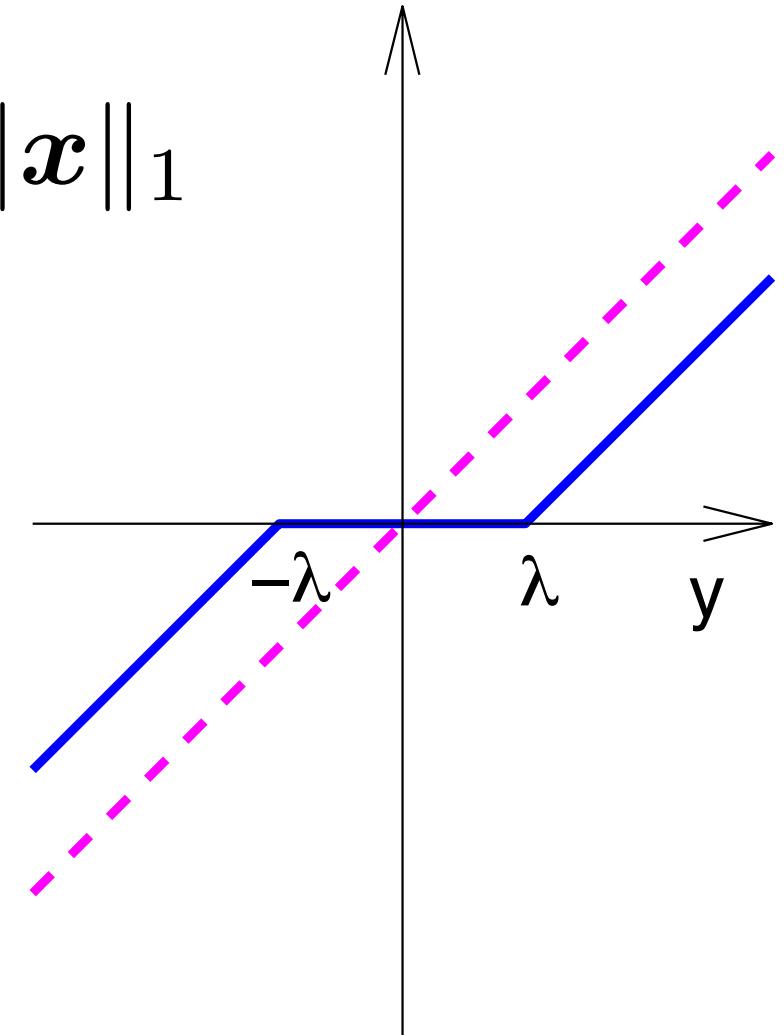
解ける問題

$$\min_{\mathbf{x}} \quad \frac{1}{2} \|\mathbf{y} - \mathbf{x}\|_2^2 + \lambda \|\mathbf{x}\|_1$$



$$\hat{x}_j = \begin{cases} y_j + \lambda & (y_j < -\lambda), \\ 0 & (-\lambda \leq y_j \leq \lambda), \\ y_j - \lambda & (y_j > \lambda) \end{cases} \quad (j = 1, \dots, n)$$

$\text{=: prox}_{\lambda}(\mathbf{y})$



近接勾配法

- いかに解ける形に帰着するか ⇒ 線形化

$$\hat{\mathbf{x}} = \underset{\mathbf{x}}{\operatorname{argmin}} (L(\mathbf{x}) + \lambda \|\mathbf{x}\|_1)$$



繰り返しアルゴリズム

$$\mathbf{x}^{t+1} = \operatorname{prox}_{\lambda \eta_t} (\mathbf{x}^t - \eta_t \nabla L(\mathbf{x}^t)).$$

近接勾配法

1. 適当に x^0 を初期化
2. 収束するまで

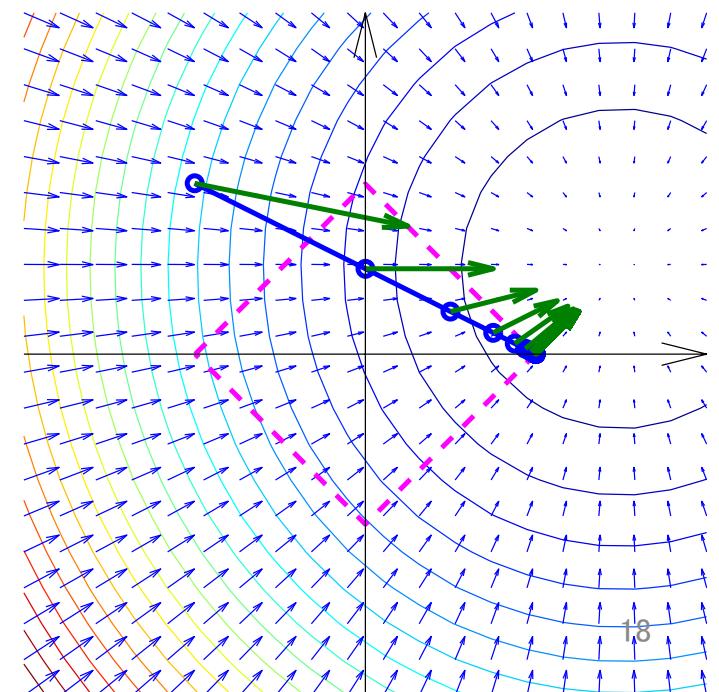
$$x^{t+1} = \text{prox}_{\lambda \eta_t} (x^t - \eta_t \nabla L(x^t))$$

利点 : 実装が簡単

欠点 : 損失項の L のヘシアンの条件

数が悪いと遅い

別名 : Iterative Shrinkage/
Thresholding, Forward-
Backward Splitting



近接勾配法—理論的な性質

- 微分可能な関数に対する勾配法と同じ
 - 微分不可能な L_1 ノルム項を解析的に扱うため
- L のヘシアンの最小、最大固有値が有限の場合、線形収束
- 最大固有値のみ有限: $O(1/k)$ で収束 (k : 反復数)
- $O(1/k^2)$ を達成するための加速法が提案されている [Nesterov 2007; Beck & Teboulle 2009]

具体例

$$\min_{\mathbf{x}} \quad \frac{1}{2} \|\mathbf{y} - \mathbf{A}\mathbf{x}\|_2^2 + \lambda \|\mathbf{x}\|_1$$

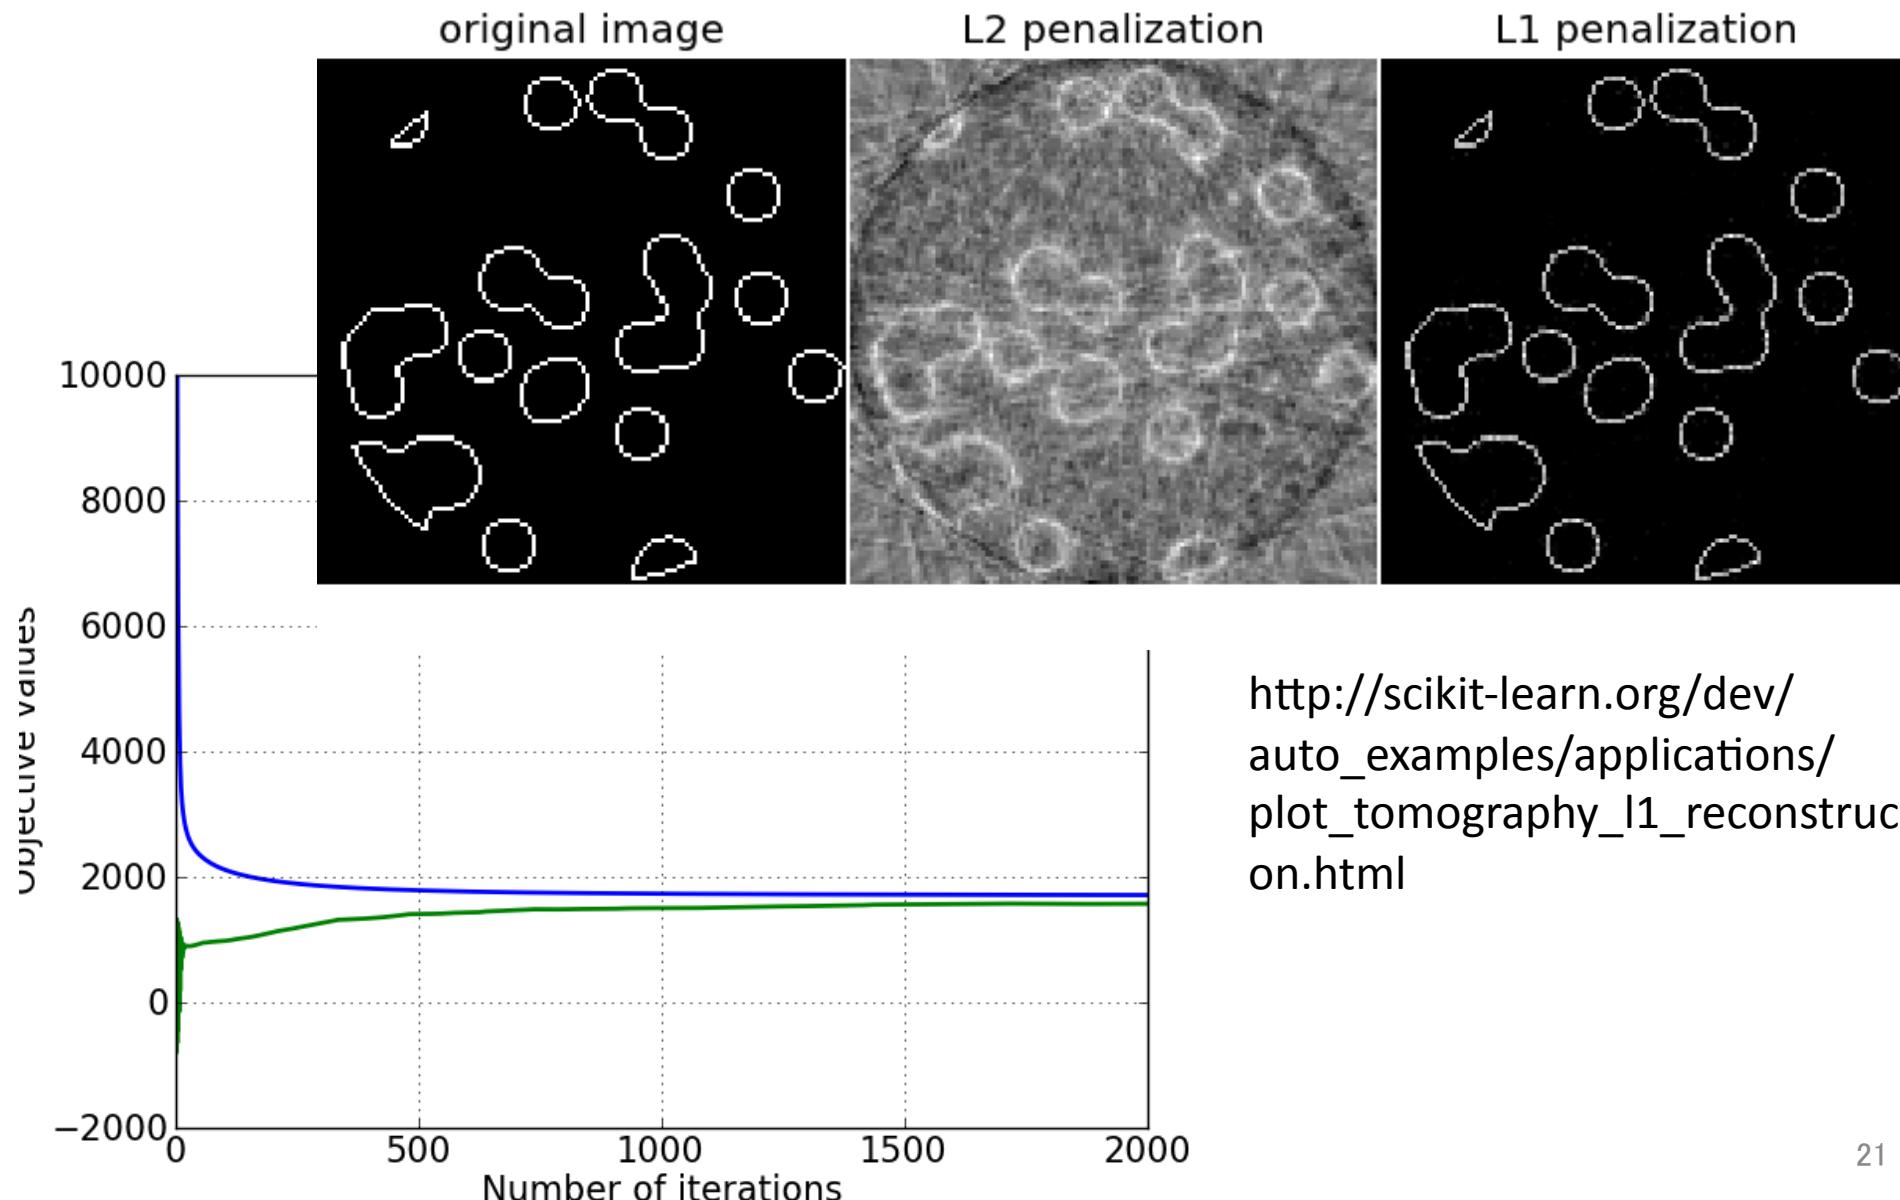


繰り返しアルゴリズム

$$\mathbf{x}^{t+1} = \text{prox}_{\lambda \eta_t} \left(\mathbf{x}^t + \eta_t \mathbf{A}^\top (\mathbf{y} - \mathbf{A}\mathbf{x}^t) \right)$$

- 主な計算コストは行列演算 $\mathbf{A}, \mathbf{A}^\top$
 - 圧縮センシングでは $\mathbf{A} \rightarrow$ フーリエ変換、 $\mathbf{A}^\top \rightarrow$ フーリエ逆変換 (FFTで高速化可能)
- 正則化項は prox さえ計算できれば一般化可能

圧縮センシングへの応用



解きたい問題 (type II)

$$\underset{x}{\text{minimize}} \quad \frac{1}{2} \|y - Ax\|_2 + \lambda \|\Psi x\|_1$$

y: 観測

x: 求めたい量

L_1 ノルム

A: デザイン行列 (観測の過程)

Ψ : スパース基底 (例: ウェーブレット変換)

交互方向乗数法—Type II のための アルゴリズム

- Type II 最適化問題

$$\min_x L(\mathbf{x}) + \lambda \|\Psi \mathbf{x}\|_1$$

微分可能 微分不可能

- 問題: prox が容易に計算できない



補助変数を導入して分離

$$\min_{x,z} L(x) + \lambda \|z\|_1,$$

$$z = \Psi x$$

拡張ラグランジュ関数

[Hestenes 69;
Powell 69]

$$\mathcal{L}(x, z, \alpha) = L(x) + \lambda \|z\|_1 + \alpha^\top (z - \Psi x) + \frac{\eta}{2} \|z - \Psi x\|_2^2$$

普通のラグランジュ関数
(Boyd “Convex Optimization”)

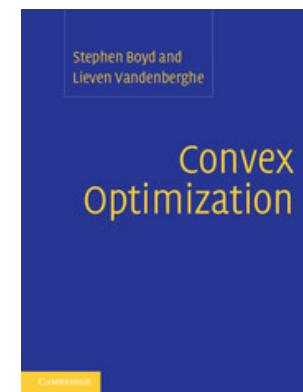
ペナルティ項

重要なポイント：

もとの問題を x, z に関して最小化することは（拡張）ラグランジュ関数の鞍点

$$\max_{\alpha} \min_{x,z} \mathcal{L}(x, z, \alpha)$$

を見つけることに等しい。



Numerical
Optimization
(Nocedal & Wright)
2006²⁴

いかに鞍点を見つけるか？

- 拡張ラグランジュ法：主問題の変数 x, z について L を同時最小化

$$\begin{cases} (\mathbf{x}^{t+1}, \mathbf{z}^{t+1}) = \operatorname{argmin}_{x,z} \mathcal{L}(x, z, \boldsymbol{\alpha}^t), \\ \boldsymbol{\alpha}^{t+1} = \boldsymbol{\alpha}^t + \eta(\mathbf{z}^{t+1} - \Psi \mathbf{x}) \end{cases}$$

結構つらい・・・

- 交互方向乗数法

$$\begin{cases} \mathbf{x}^{t+1} = \operatorname{argmin}_x \mathcal{L}(x, \mathbf{z}^t, \boldsymbol{\alpha}^t), \\ \mathbf{z}^{t+1} = \operatorname{argmin}_z \mathcal{L}(\mathbf{x}^{t+1}, z, \boldsymbol{\alpha}^t), \\ \boldsymbol{\alpha}^{t+1} = \boldsymbol{\alpha}^t + \eta(\mathbf{z}^{t+1} - \Psi \mathbf{x}^{t+1}) \end{cases}$$

交互に最適化

双対問題に対する勾配法

交互方向乗数法—理論的な性質

- 収束性：緩い仮定のもとで証明可能 (Boyd 2011 参照)
- 収束レート
 - $O(1/k)$: He & Yuan 2012
 - $O(\exp(-k))$ (線形収束): Deng & Yin 2012
 - 実際は近接勾配法より速い感じ

具体例

$$\min_{\mathbf{x}} \quad \frac{1}{2\lambda} \|\mathbf{y} - \mathbf{A}\mathbf{x}\|_2^2 + \|\Psi\mathbf{x}\|_1$$



拡張ラグランジュ関数

$$\mathcal{L}(\mathbf{x}, \mathbf{z}, \boldsymbol{\alpha}) = \frac{1}{2\lambda} \|\mathbf{y} - \mathbf{A}\mathbf{x}\|_2^2 + \|\mathbf{z}\|_1 + \boldsymbol{\alpha}^\top (\mathbf{z} - \Psi\mathbf{x}) + \frac{\eta}{2} \|\mathbf{z} - \Psi\mathbf{x}\|_2^2$$



繰り返しアルゴリズム

$$\begin{cases} \mathbf{x}^{t+1} = \operatorname{argmin}_{\mathbf{x}} \left(\frac{1}{2\lambda} \|\mathbf{y} - \mathbf{A}\mathbf{x}\|_2^2 + \frac{\eta}{2} \|\mathbf{z}^t - \Psi\mathbf{x} + \boldsymbol{\alpha}^t\|_2^2 \right), \\ \mathbf{z}^{t+1} = \operatorname{argmin}_{\mathbf{z}} \left(\|\mathbf{z}\|_1 + \frac{\eta}{2} \|\mathbf{z} - \Psi\mathbf{x}^{t+1} + \boldsymbol{\alpha}^t\|_2^2 \right), \\ \boldsymbol{\alpha}^{t+1} = \boldsymbol{\alpha}^t + (\mathbf{z}^{t+1} - \Psi\mathbf{x}^{t+1}) \end{cases}$$

まとめ

- スパースに表現することの2つの側面
 - データの圧縮
 - モデルの圧縮
- 2つの最適化問題
 - Type I – 正則化項がバラけている
 - Type II – 正則化項がバラけていない
- 最適化アルゴリズム
 - (加速付き) 近接勾配法 – 21世紀の勾配法?
 - 交互方向乗数法

お話しきなかつた話題

- 拡張ラグランジュ法／交互方向乗数法をType I にも適用できないか?
 - Type I の双対問題は Type II
 - 双対拡張ラグランジュ法 (DAL)
- L_1 正則化以外の正則化項
 - グループ L_1 正則化 (マルチカーネル学習)
 - トレスノルム正則化
 - Prox作用素が計算できるのでほとんど同じ議論
- より複雑な正則化項
 - Type I、Type II どちらかになっていることが多い₂₉